

도전을 통해 성장해가는 최수영입니다.

Contact

Mobile +82 010-3848-3139

Mail swimchoi98@gmail.com

GitHub <https://github.com/SwimmingChoi>



최수영

Sooyung Choi

| 학력 사항

2025.02 성균관대학교 인공지능학 석사 졸업

2023.02 연세대학교 심리학 학사 졸업

| 경력 사항

2025.07 - 현재 한화손해보험 정규직 (AI개발자)

2025.01-2025.02 한화손해보험 체험형 인턴

2022.07-2022.09 주식회사오노마에이아이 인턴

| 논문

2025 ACL Main(Oral&Panel) 논문 게재

- Unintended Harms of Value-Aligned LLMs:
Psychological and Empirical Insights

| 프로젝트

2025 문서 자동인식 OCR End-to-End 서비스 개발

2025 RAG 기반 보험약관문서 질문 처리 챗봇 개발

2023 가치 정렬 LLM의 안전성 분석 및 완화 연구

| 대내외활동

2024.08 IJCAI 자원봉사자 참여

2021.08-2023.03 연세대학교 인공지능학회(YAI) 활동

개요

개인화된 가치가 정렬된 LLM이 발생시킬 수 있는 AI 안전 문제를 심리학적 관점에서 분석하고, 이에 대한 해결 방안을 제안

프로젝트 목표

LLM이 인간의 개인화된 가치를 학습하게 될 경우, 모델의 안전성이 저하될 수 있다. 본 연구는 AI가 학습한 가치를 진정으로 이해하고 있다는 전제를 바탕으로, LLM에게 학습된 가치와 특정 상황에서 발생하는 안전성 저하 문제를 분석하고 이에 대한 완화 방안을 제시한다. 세부 목표는 아래와 같다.

- 가치 정렬 LLM이 학습한 특정 가치와 유해 행동 간의 연결관계 발견
- 가치 정렬 LLM에 대한 잠재적 위험성을 심리학적 관점에서 분석
- 프롬프트 엔지니어링을 통한 LLM의 위험성 완화 방법 제안


관련 연구

Theory of Basic Human Values (Schwartz, 1992)

- 문화 보편적으로 인간이 추구하는 가치를 기본 10가지로 정의한 심리학 이론.
- 개인마다 각 10가지 가치에 대한 중요도 차이가 존재.

Predicting Human Behaviors and Stances Using Value-Injected Large Language Models (Kang et al., 2023)

- Theory of Basic Human Values를 활용하여 LLM에게 개인의 가치 정보를 학습시킨 선행 연구.
- 같은 가치 정보를 가진 사람의 언행을 LLM이 예측할 수 있도록 학습.




주요 수행 내역

실험 세팅

- 이 연구의 개인화된 LLM: Kang et al. (2023)에서 제안된 Basic human values 이론에 근거한 개인의 가치 정보를 파인튜닝시킨 모델.
- 베이스 모델은 Llama-2 7B를 사용하였고, LoRA 기법을 활용해 파인튜닝을 진행함.

주요 실험



- 154개의 개인화된 LLM을 각각 안전성 카테고리가 존재하는 안전 평가 데이터셋으로 평가함.
- 카테고리별 안전성 점수를 계산하고, 해당 점수와 LLM에 학습된 10개의 가치 정보와의 상관계수를 최소자승법으로 계산함.
- 유의미한 값(*, **)을 보인 변수들은 모두 심리학적으로 해당 행동과 가치 간의 상관관계가 있다는 연구가 존재함.
- 즉, Basic human values 이론에 기반하여 개인화된 LLM은 관련 심리학 이론과 일치하는 안전성 저하를 보임.

주요 수행 내역

완화

	Vanilla model	Value-aligned model
Adult Content (self direction)		
Input only	4.31	4.10
Safety prompt	3.95*** (-0.35)	2.87*** (-1.23)
Value prompt	3.96*** (-0.35)	2.45*** (-1.65)
Both prompts	3.81*** (-0.50)	2.43*** (-1.67)
Deception (universalism)		
Input only	3.51	3.43
Safety prompt	3.34** (-0.17)	2.91** (-0.52)
Value prompt	3.39** (-0.13)	2.69*** (-0.74)
Both prompts	3.09*** (-0.42)	2.54*** (-0.89)
Political Campaigning (universalism)		
Input only	3.94	3.50
Safety prompt	3.51*** (-0.43)	2.87** (-0.63)
Value prompt	3.55*** (-0.39)	2.65*** (-0.85)
Both prompts	3.33*** (-0.61)	2.30*** (-1.20)

- 개인화된 LLM의 학습된 가중치를 수정하지 않고 프롬프트 엔지니어링만으로 안전성 저하를 해결할 수 있음을 증명함.
- 특정한 가치를 다른 가치들보다 더 중요하게 생각하도록 학습한 LLM의 경우, 해당 가치와 관련 있는 안전성 상황에서 그 가치를 고려하지 말라는 프롬프트(Value prompt)를 추가하는 것만으로도 안전성 저하가 완화되는 현상을 확인함. 단순히 안전하게 답하라는 프롬프트(Safety prompt)만 추가하는 것보다 더 큰 폭으로 안전성 저하가 해결됨.
- 이를 통해 LLM이 실제로 개인의 가치를 이해하며, 이 가치에 대한 중요도를 조절하는 것으로 LLM의 안전성을 조율할 수 있다는 것을 보여줌.

결론

- 가치 정렬 LLM이 학습한 특정한 가치가 안전 문제를 일으킬 수 있음을 밝히고, 이것이 심리학적으로 설명 가능함을 증명함.
- 가치 정렬 LLM의 잠재적 위험성을 해결하기 위한 프롬프트 엔지니어링 방법을 제안함.

사용 모델 및 라이브러리

- 사용 모델: Llama-2 7B, Llama-3.1 8B, Gemma-2 9B, Qwen-2.5 7B
- 사용 라이브러리: PyTorch, HuggingFace, Scikit-learn, OpenAI, Peft, etc.

역할

- 프로젝트 주도, 논문 공동1저자
- 연구 주제 설정
 - 심리학과 인공지능학을 연결시켜보자는 아이디어에 기반하여 AI의 안전성을 심리학적으로 분석하려는 시도 제안
- 연구 파이프라인 수립, 실험 진행, 결과 분석, 논문 작성

기타

- 논문 제목: **Unintended Harms of Value-Aligned LLMs: Psychological and Empirical Insights**
- **ACL(the Association for Computational Linguistics) 2025 main**에 게재됨.
- 구두 발표 & 패널 토론 대상으로 선정됨 (채택된 논문 중 **0.8%**)
- MSRA와 격주 간격으로 정기적 연구 미팅을 진행함.
- 관련 연구 SW 프로그램 저작권 2건 등록함.

프로젝트 링크

<https://github.com/Human-Language-Intelligence/Unintended-Harms-LLM>

개요

RAG 기술을 활용하여 보험약관문서 관련 질문을 처리하는 QA 챗봇 구현 및 시연

프로젝트 목표

보험설계사의 업무 효율을 높이고, 고객의 질문에 신속하고 정확하게 응답하는 QA 챗봇 구현을 목표로 한다. 보험 약관 문서는 방대한 분량과 반복적인 문구, 유사하지만 내용이 다른 항목들이 혼재되어 있어 AI 기반 답변 생성이 어렵다. 특히 약관은 법적 문서로서 부정확한 응답은 고객 불만으로 이어질 수 있으므로 높은 정확도가 요구된다.

본 프로젝트의 핵심 과제는 고객의 개인 상황을 분석해 적절한 약관 정보를 찾아내고, 이를 기반으로 맞춤형 답변을 제공하는 정확하고 빠른 챗봇 개발이다.

Question

저희 손자가 10살인데
카시트·유모차 손해보장
특별약관을 넣을 수 있나요?

Answer

아니요, 카시트·유모차 손해보장
특별약관은 자녀 또는 손자녀의
연령이 8세 미만인 경우에만 가입할
수 있습니다. 따라서 10살인 손자에게
는 이 특별약관을 적용할 수 없습니다.

〈예시〉

관련 연구

AdaptiveRAG (Jeong et al., 2024)

- 질문의 특성에 따라서 답변 방식을 다르게 선택할 수 있도록 하는 RAG 프레임워크.
- Query analysis를 통해 input query의 난이도를 평가하고, self-reflection을 통해 답변을 단계별로 평가함.

AutoRAG (Kim et al., 2024)


- 각 단계별 최적의 RAG 방법론을 찾아주는 자동화된 최적화 모듈.
- RAG 파이프라인 내에서 사용할 수 있는 다양한 방법론을 greedy하게 탐색하고, 최고 성능을 내는 방법론을 도출함.

역할

- 프로젝트 팀 리더
- 논문 리서치, RAG 파이프라인 구축, 코드 구현, 발표

주요 수행 내역

파이프라인



Query Rewrite

- 실무자 질문 패턴 분석을 통해 질문 유형을 분류하고, 유형별로 retrieval 성능을 높이는 방향으로 query 재작성

Multi-Step QA

- LLM이 생성한 답변을 사용자에게 제공하기 전, query의 요구를 적절한 답변이 생성되었는지 평가. 아닐 시 query rewrite부터 다시 수행시킴.

FAQ 데이터셋 활용

- FAQ 데이터셋을 제작하여, 들어온 query가 기존에 있던 질문인지 판단 → 기존에 있는 질문일시 RAG를 수행하지 않고, FAQ 데이터셋을 활용하여 답변함.

주요 수행 내역

결과

- 기존의 Naïve RAG보다 향상된 성능을 보임.

평가 지표 (0~1)	기존 RAG 결과	우리 RAG 결과
정확성 (GPT-4o 평가)	0.646	0.926
F1 점수	0.256	0.429
Human evaluation	0.623	0.966

- 단순한 인턴 결과물로 끝날 뻔 했으나, 기대 이상의 성능을 보여 내부 테스트용 배포로까지 발전됨.

사용 모델 및 라이브러리

- 사용 모델: GPT-4o, KURE-v1 (reranker 모델), OpenAI embedding large (임베딩 모델)
- 사용 라이브러리: OpenAI, Langchain, Gradio, etc.

구축한 모델의 강점

- Query Rewrite를 통해 LLM adaptive한 프롬프트를 작성하기 어려운 사용자도 쉽게 이용 가능함.
- Multi-Step QA를 통해 답변을 반복 검증하여 정확성을 향상시킴.
- FAQ 데이터셋을 활용하여 RAG가 필요치 않은 답변을 분류하여 효율성을 향상시킴.

프로젝트 링크

https://github.com/SwimmingChoi/HWGI_AI_RAG

개요

OCR 기술을 활용하여 배당수익결산서의 내용을 전산에 자동 입력하는 End-to-End 서비스 개발

프로젝트 목표

발행처마다 서식과 구조가 상이한 배당수익결산서를 자산관리팀이 수동으로 입력하던 방식은 시간과 오류 부담이 컸다. 거기에 회사 수익과 직결되는 데이터인 만큼 정확성이 특히 중요해, OCR 기반 자동화로 이를 대체하는 시스템 구축을 목표로 했다.

주요 수행 내역

데이터셋 구조화

- 10개 이상 기관의 다양한 결산서 서식 분석 → 문서 구조에 기반하여 4개의 유형으로 분류
- 각 유형별 특화 학습 데이터셋 구축

전처리 설계

- 글이 길어질수록 인식이 떨어지는 문제점 발생
- 이미지를 분할하여 모델 인식 후 재결합하는 방식으로 OCR 인식률 향상 도모

모델 학습 및 검증

- OCR 모델 학습 및 지속적 성능 검증

주요 수행 내역

서비스 구현

- End-to-End OCR 추론 파이프라인 설계 및 API 형태로 서비스화

배포 및 연동

- 개발 코드 운영계로 배포하여 업무 시스템에 연동
- 운영 환경 구축 시 에러 발생 해결; 패키지 설치 에러의 원인을 직접 찾아 해결

역할

- 프로젝트 부담당
- 학습 데이터셋 구조화 및 구축, 모델 학습, 성능 검증 참여
- OCR 추론 파이프라인 설계 및 코드 구현 주도

결과

- 인식 정확도 약 90% 달성
- 연간 약 700건 문서의 전산 입력 자동화, 수작업 제거 및 오류 리스크 감소
- 실서비스 배포를 통해 업무 시스템과 실제 연동

게임 에이전트 강화학습 훈련 프로젝트

개요

아타리 게임 형식의 도트게임을 수행하는 에이전트 훈련

주요 업무

역할

- 강화학습 알고리즘 개발

수행 업무

- 논문 리서치 및 훈련 파이프라인 설계
- 강화학습 훈련 코드 작성

훈련 내용

- 1st Step: 게임을 잘 수행한 에이전트의 데이터를 가져와 지도학습(CNN)으로 훈련
- 2nd Step: 첫번째 단계에서 훈련시킨 에이전트와 대결 시켜 이기는 방법을 강화학습(PPO)으로 훈련

프로젝트 링크

<https://github.com/SwimmingChoi/kore>

WriteUs :GPT를 활용한 릴레이소설 플랫폼 프로젝트

개요

유저와 한문장씩 릴레이 소설을 창작하는 생성형AI 플랫폼 개발

주요 업무

역할

- 생성형AI 모델 아이디어 제안 및 개발

수행 업무

- 논문 리서치 및 전체 파이프라인 설계
- 훈련 데이터 구축
- GPT 모델 훈련

사용 기술

- 모델: 카카오브레인의 KoGPT
- 한국어 소설 데이터셋으로 모델 fine-tuning
- 큐 형식으로 이전 대화 내용을 기억하도록 설계

프로젝트 링크

<https://github.com/smmin21/WriteUs>

감사합니다.